

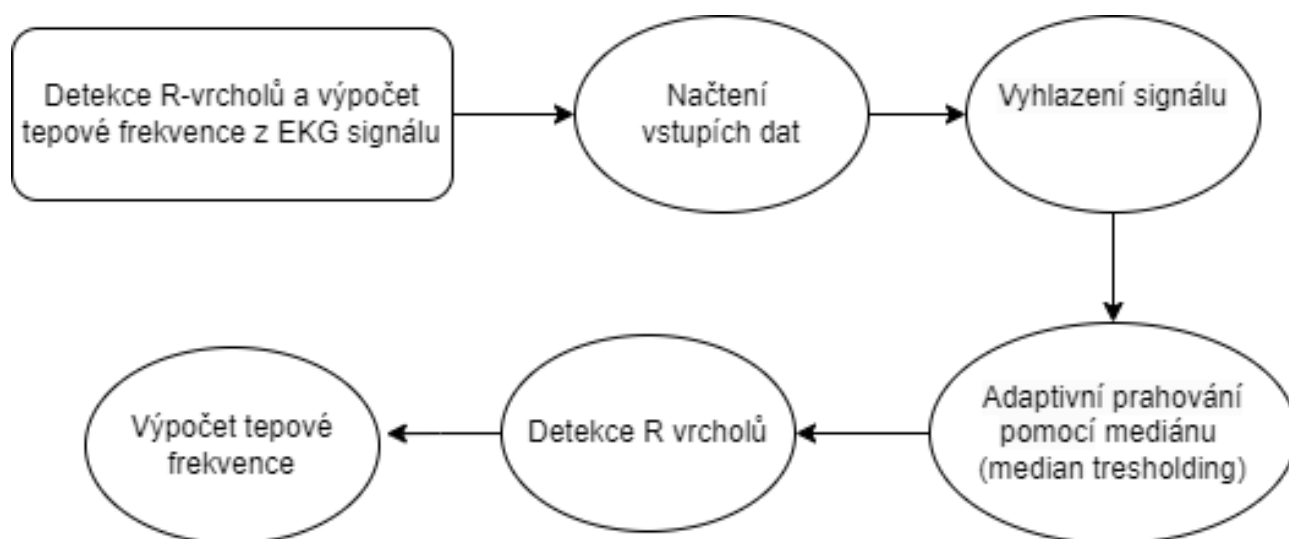
Zadání I. seminární práce z předmětu Počítačové zpracování signálu (KI/PZS)

Zadání:

Ve zdrojové databázi najdete celkem 17 měření EKG signálu. Signál je již filtrován a centralizován kolem podélné osy. EKG signál obsahuje dominantní peaky, které se nazývají R vrcholy. Vzdálenost těchto vrcholů určuje dobu mezi jednotlivými tepy. Počet tepů za minutu je tedy počet R vrcholů v signálu o délce jedné minuty. Navrhněte algoritmus, který bude automaticky detekovat počet R vrcholů v EKG signálech a prezentuje tepovou frekvenci při jednotlivých jízdách/měřeních. Váš algoritmus následně otestujte na databázi MIT-BIH <https://physionet.org/content/nsrdb/1.0.0/> a prezentujte jeho úspěšnost vzhledem k anotovaným datům z databáze.

Postup řešení

Programová část práce byla implementována v jazyce Python s využitím knihoven **numpy**, **wfdb** pro načítání EKG dat a **matplotlib** pro vizualizaci. Následující kroky představují základní algoritmus:



1. Načtení dat EKG:


Data byla načtena pomocí knihovny **wfdb**, která umožňuje čtení a zpracování EKG signálů.

2. Vyhlazení signálu:

Implementace mediánového filtru pomocí konvoluce pro redukci šumu v EKG signálu. Důležitý aspekt při konvoluci je velikost konvolučního jádra, kterou jsme zvolili 3. Výběr jsme provedli s ohledem na kompromis mezi efektivitou odstranění šumu a zachováním charakteristik signálu.


3. Adaptivní prahování založené na mediánu:

Adaptivní prahování je metoda pro dynamické nastavení prahu, který se mění podle lokálních vlastností signálu. Pro každý bod signálu definovaného oknem je vypočítán medián z bodů z tohoto okna.



4. Detekce R-vrcholů:

Implementace algoritmu pro nalezení R-vrcholů na základě adaptivního prahu a lokálních vlastností signálu. Je tady využit adaptivní práh, který se přizpůsobuje lokálními vlastnostem signálu. Důležité je zde zvolit správné okno pro výpočet mediánu.



Výpočet tepové frekvence:

Výpočet tepové frekvence na základě počtu detekovaných R-vrcholů za minutu.

Vzorek	bpm
drive01	76.25876002016227
drive02	68.93566322478156
drive03	80.65619400518413
drive04	72.76065977867519
drive05	67.85514680549707
drive06	77.92811980033277
drive07	74.51821842705351
drive08	65.1890453046576
drive09	70.92742057832933
drive10	76.70648464163821
drive11	64.92208909776924
drive12	64.14747796373238
drive13	78.41337288543254
drive14	78.41337288543254
drive15	64.03401143870047
drive16	75.83763654419067
drive17a	72.59508686002908
drive17b	71.50822166800525

Závěr

Naším měřením jsme získali příslušné tepové hodnoty jednotlivých účastníků měření. Naše indikované výsledky nabývají reálných hodnot.

Zadání:

Ve zdrojové databázi najdete celkem 17 měření obsahující EKG signál. Signály jsou již filtrované a centralizované kolem podélné osy. Různá měření jsou získána s různou vzorkovací frekvencí. U všech signálů analyzujte vzorkovací frekvenci a proveďte sjednocení na tu dominantní z nich. Pro tyto převzorkované signály proveďte korelační analýzu a prezentujte, jak jsou si signály napříč měřeními podobné. Pro smysluplné provedení této analýzy je potřeba nejprve srovnat signály na stejný počátek, např. dle pozice prvního dominantního R peaku. Protože se délky jednotlivých signálů neshodují, je také nutné zvolit vhodnou délku korelační funkce, a to například analýzou autokorelačních funkcí samostatných signálů.

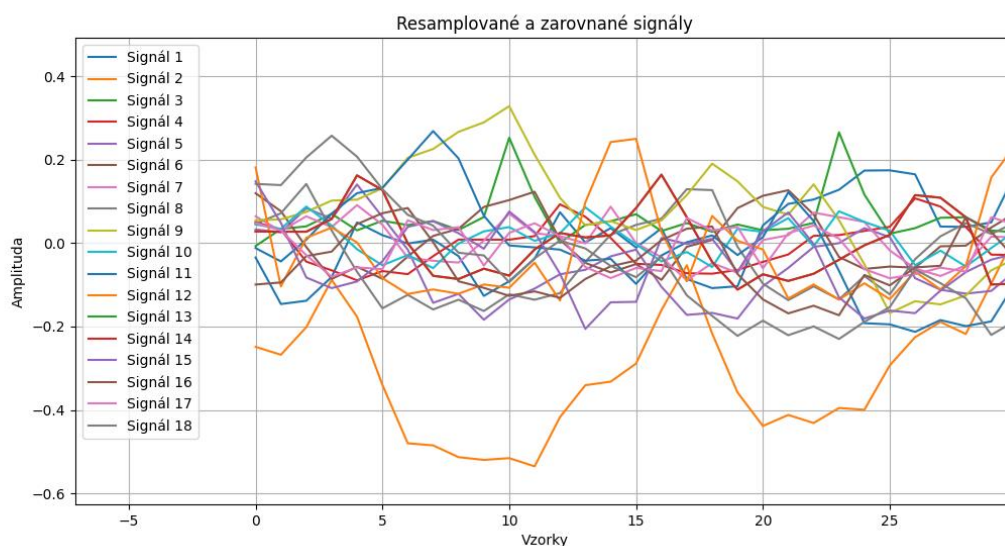
Postup řešení

1. Příprava a načtení dat

Jako první jsem načetl všechny EKG signály a zjistili jsme jejich vzorkovací frekvence.

2. Vyčištění a zpracování signálu

Na každý signál jsme aplikovali mediánový filtr pro vyčištění a vyhlazení signálu. Následně jsme pomocí adaptivního mediánového okna získali dominantní R-peaky, které slouží pro srovnání signálů. Aby se zajistila správná detekce, porovnávali jsme signály s adaptivními prahovými hodnotami a identifikovali jejich lokální maxima, dále jsme je filtrovali na základě minimální vzdálenosti mezi jednotlivými vrcholy.



3. Resampling a zarovnání signálů

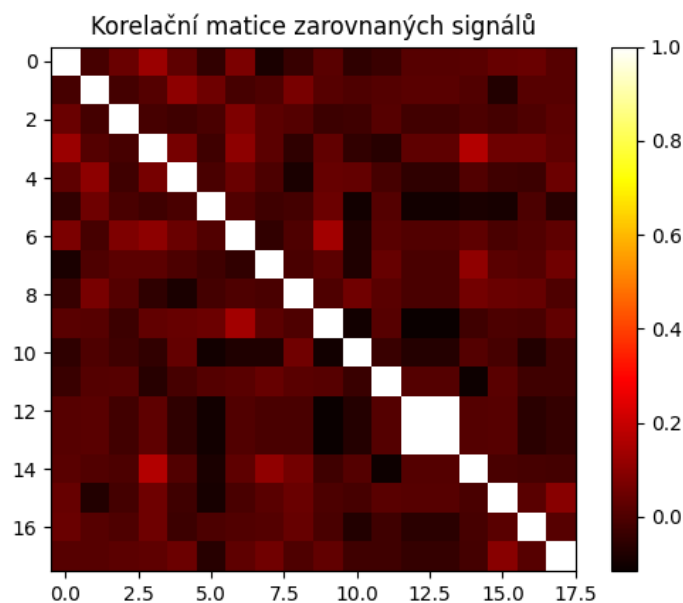
Po získání dominantní vzorkovací frekvence celého datasetu přichází na řadu resampling. Po zpracování všech signálů vybereme nejčastější vzorkovací frekvenci, kterou využijeme pro převzorkování jednotlivých signálů na dominantní frekvenci. Když jsou všechny signály převzorkovány, tak dojde k zarovnání začátků signálu k prvnímu dominantnímu peaku.

Po zarovnání a převzorkování všech signálů dojde ke korelační analýze, která nám pomocí korelačního koeficientu ukazuje vzájemnou závislost EKG signálů.

4. Korelační analýza

Pro porovnání závislostí jednotlivých signálů jsme využili korelační analýzu. Pro interpretaci výsledků jsme vybrali tabulkovou formu pro jasný přehledný náhled do dat společně s vizualizací pomocí heatmapy pro rychlé pochopení vztahů mezi signály.

Signal	Signal 1	Signal 2	Signal 3	Signal 4	Signal 5	Signal 6	Signal 7	Signal 8	Signal 9	Signal 10	Signal 11	Signal 12	Signal 13	Signal 14	Signal 15	Signal 16	Signal 17	Signal 18
Signal 1	1	-0,0119	0,0454	0,1257	0,0253	-0,0501	0,0723	-0,0865	-0,0409	0,0194	-0,0524	-0,0365	0,0145	0,0145	0,0188	0,0389	0,0433	0,0141
Signal 2	-0,0119	1	-0,0166	0,0091	0,1043	0,0528	-0,0124	0,0013	0,069	0,0125	0,0008	0,0096	0,0153	0,0153	0,0052	-0,0729	0,0135	0,0128
Signal 3	0,0454	-0,0166	1	-0,0146	-0,0276	-0,0078	0,0799	0,0213	0,008	-0,0312	-0,0276	0,014	-0,0204	-0,0204	-0,0059	-0,0153	0,0007	0,022
Signal 4	0,1257	0,0091	-0,0146	1	0,0664	-0,0281	0,1038	0,0203	-0,0518	0,0292	-0,0477	-0,0648	0,025	0,025	0,1637	0,0501	0,0519	0,0271
Signal 5	0,0253	0,1043	-0,0276	0,0664	1	-0,0107	0,0414	-0,005	-0,0867	0,0382	0,0366	-0,0126	-0,0515	-0,0515	0,0026	-0,025	-0,0297	0,0482
Signal 6	-0,0501	0,0528	-0,0078	-0,0281	-0,0107	1	0,0065	-0,0251	-0,0196	0,0491	-0,1024	0,0101	-0,1006	-0,1006	-0,0874	-0,0906	-0,0036	-0,0671
Signal 7	0,0723	-0,0124	0,0799	0,1038	0,0414	0,0065	1	-0,0463	0,0007	0,1415	-0,0794	0,0174	0,0064	0,0064	0,0243	-0,0095	0,0032	0,0247
Signal 8	-0,0865	0,0013	0,0213	0,0203	-0,005	-0,0251	-0,0463	1	-0,0095	0,0229	-0,0783	0,0406	-0,009	-0,009	0,1111	0,0159	0,0102	0,0563
Signal 9	-0,0409	0,069	0,008	-0,0518	-0,0867	-0,0196	0,0007	-0,0095	1	0,0009	0,0579	0,018	-0,0073	-0,0073	0,0593	0,0446	0,0386	-0,0002
Signal 10	0,0194	0,0125	-0,0312	0,0292	0,0382	0,0491	0,1415	0,0229	0,0009	1	-0,102	0,0111	-0,1155	-0,1155	-0,0284	-0,0033	-0,0104	0,0309
Signal 11	-0,0524	0,0008	-0,0276	-0,0477	0,0366	-0,1024	-0,0794	-0,0783	0,0579	-0,102	1	-0,0339	-0,0677	-0,0677	0,0095	-0,0132	-0,0733	-0,0241
Signal 12	-0,0365	0,0096	0,014	-0,0648	-0,0126	0,0101	0,0174	0,0406	0,018	0,0111	-0,0339	1	0,0096	0,0096	0,1082	0,0175	-0,0255	-0,0279
Signal 13	0,0145	0,0153	-0,0204	0,025	-0,0515	-0,1006	0,0064	-0,009	-0,0073	-0,1155	-0,0677	0,0096	1	1	0,0074	0,0142	-0,0608	-0,0426
Signal 14	0,0145	0,0153	-0,0204	0,025	-0,0515	-0,1006	0,0064	-0,009	-0,0073	-0,1155	-0,0677	0,0096	1	1	0,0074	0,0142	-0,0608	-0,0426
Signal 15	0,0188	0,0052	-0,0059	0,1637	0,0026	-0,0874	0,0243	0,1111	0,0593	-0,0284	0,0095	-0,1082	0,0074	0,0074	1	-0,0075	-0,0144	-0,0167
Signal 16	0,0389	-0,0729	-0,0153	0,0501	-0,025	-0,0906	-0,0095	0,0159	0,0446	-0,0033	-0,0132	0,0175	0,0142	0,0142	-0,0075	1	0,0184	0,0974
Signal 17	0,0433	0,0135	0,0007	0,0519	-0,0297	-0,0036	0,0032	0,0102	0,0386	-0,0104	-0,0733	-0,0255	-0,0608	-0,0608	-0,0144	0,0184	1	0,0118
Signal 18	0,0141	0,0128	0,022	0,0271	0,0482	-0,0671	0,0247	0,0563	-0,0002	0,0309	-0,0241	-0,0279	-0,0426	-0,0426	-0,0167	0,0974	0,0118	1



Závěr

Zpracování signálů zahrnovalo několik kroků pro zajištění správné detekce R-peaků. Použití mediánového filtru zajistilo odolnost vůči šumu. Po jejich zarovnání jsme došli pomocí korelační analýzy k závěru, že většina signálů má nízké korelační koeficienty s ostatními signály, což naznačuje vysokou variabilitu mezi měřeními nebo individuální rozdíly v EKG signálech.

Zadání:

Ve zdrojové databázi najdete celkem 17 měření EMG signálu. Signál je již filtrován a centralizován kolem podélné osy. EMG signály zachycují aktivitu svalů během jízdy. Pro všech 17 měření spočítejte integrované EMG (iEMG) pomocí vzorce


$$iEMG = \int_0^t |f(t)| dt$$

kde, t je doba záznamu, $f(t)$ je EMG signál a $||$ symbolizuje absolutní hodnotu. Dále detekujte oblasti, kde u jednotlivých signálů dochází k nárůstu a poklesu aktivity, a to pomocí okénkové varianty iEMG a derivace funkce. Velikost okénka zvolte tak, aby byly výsledky statisticky spolehlivé.

Postup řešení

1. Příprava a načtení dat

Jako první jsme načtli všechny EMG signály společně s jejich vzorkovací frekvencí.



2. Výpočet integrovaného EMG (iEMG)

Po úspěšném načtení přichází čas na integraci získaných vstupních dat pomocí následujícího vzorce:

$$iEMG = \int_0^t |f(t)| dt$$

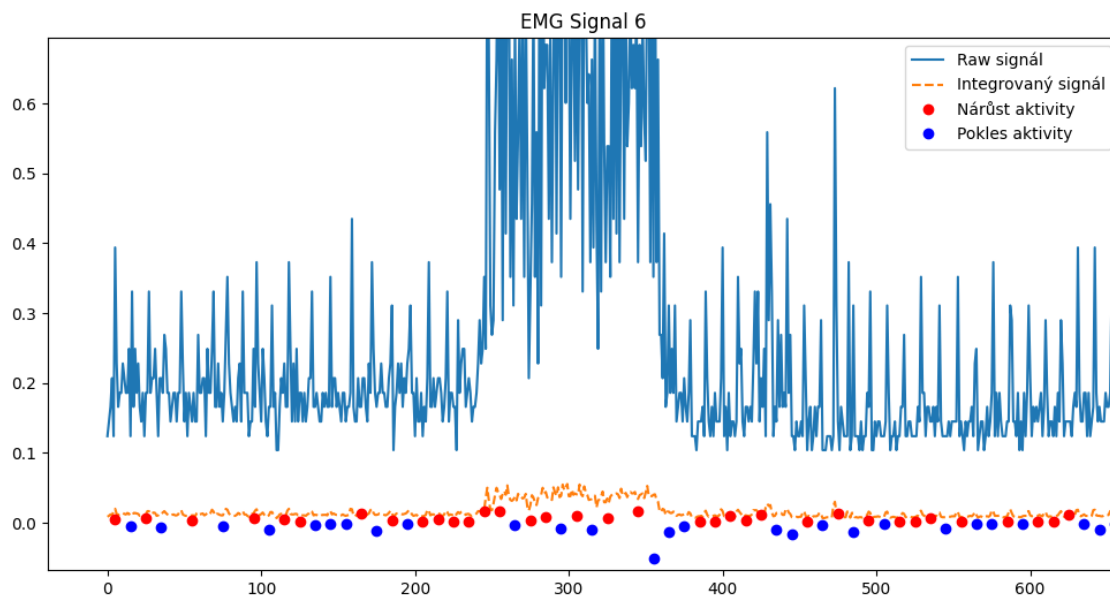
kde $f(t)$ je EMG signál a t je doba jeho záznamu.

3. Detekce oblastí nárůstu a poklesu aktivity

Pro detekci oblastí nárůstu a poklesu aktivity použijeme následující postup:

- Použijeme okénkovou variantu iEMG, což znamená, že vypočítáme iEMG pro jednotlivá okénka signálu.
- Vypočítáme derivaci iEMG signálu v těchto okénkách.
- Na základě prahové hodnoty rozhodneme, které oblasti vykazují nárůst (kladná derivace) a které pokles (záporná derivace) aktivity.

Velikost okénka zvolíme tak, aby výsledky byly statisticky spolehlivé. To znamená, že okénko musí být dostatečně velké na to, aby zachytilo relevantní změny v signálu, ale zároveň dostatečně malé na to, aby zachovalo detailní informace o změnách aktivity.



Závěr

Po provedení analýzy EMG signálů pro všech 17 měření jsme získali integrovaný EMG (iEMG) pro každý záznam, což nám poskytlo celkový přehled o svalové aktivitě během jízd. Pomocí okénkované varianty iEMG a derivace jsme identifikovali oblasti nárůstu a poklesu svalové aktivity. Tato metoda nám umožnila detailněji sledovat dynamiku svalových kontrakcí a relaxací v průběhu času.